

# 基于风格迁移的光学遥感图像云雾去除

摘要:

关键词:

## 1 引言

### 什么是光学遥感图像

光学遥感图像作为一种重要的地球观测手段，在全球环境监测、自然资源管理以及城市规划等多个领域中发挥着不可替代的作用。通过卫星或无人机等遥感平台获取地表的光谱和空间信息，光学遥感图像能够提供精确且丰富的地理数据支持，从而降低农业、渔业、军事、资源普查、城市规划等实际应用领域的成本。

### 为何需要光学遥感图像去雾

然而，尽管光学遥感图像具有多种优势，其在实际应用中常常面临大气环境因素的干扰，特别是云雾的遮挡问题尤为突出。根据国际卫星云气候学计划（ISCCP）发布的研究数据，地球表面每年平均有超过 60% 的区域被云层覆盖<sup>[1]</sup>。云雾不仅会遮挡地表的真实信息，还会对图像的整体质量产生显著的负面影响。云雾的存在会导致光学遥感图像中地物的边界模糊、纹理丢失，甚至完全覆盖地表目标，导致这些信息无法被正确解读。这种干扰在云量密集的地区和季节尤为明显，使得原本有价值的遥感数据在解译过程中变得不可靠，极大地限制了光学遥感图像的实际应用效果。

### 光学遥感图像中的三种云雾类型

光学遥感图像中存在的云雾可以分为三类，即薄云、厚云与云影<sup>[2]</sup>。薄云具有较高的透光性，使得部分地表信息仍然能够通过云层被感知。然而，尽管薄云并未完全遮挡地表目标，其存在仍然会导致图像对比度的降低和细节信息的模糊，从而影响遥感影像的质量和后续分析的准确性。厚云则完全遮挡地表信息，导致这些被覆盖的区域丧失了可用的地理和光谱数据。这使得从单幅图像中去除厚云成为一个具有局限性的问题，从而导致厚云下的信息无法通过单一时相的图像恢复，解决这一问题通常需要多时相数据的支持。通过结合不同时间点拍摄的影像，能够在某些时相下未被厚云覆盖的区域恢复地表信息，进而实现对厚云区域的重建和还原。因此，厚云的去除往往依赖于多源数据的融合，而不仅仅是对单幅影像的处理。云影是在云层遮挡阳光时，投射到地表的阴影区域。与云雾不同，云影并不会直接遮挡地表信息，而是通过减少地表的光照，使得该区域的光谱反射率显著降低。这种现象会导致地物的光谱特征发生改变，使得地物在影像中的表现与实际情况有所偏离。特别是在多光谱或高光谱遥感数据中，云影会干扰不同波段的反射特性，从而影响图像的分类和解译精度。

**介绍本文工作重心：1.基于风格迁移的云雾去除 2.一种云雾添加算法（提一下前人算法，并介绍缺陷与改进）**

近年来，随着深度学习技术的快速发展，人工智能在图像处理领域展现出了强大的能力。在图像风格迁移（Style Transfer）方面，深度学习模型能够在保留源域图像原有内容的同时，实现特定目标的去除和增强。因此，风格迁移技术在遥感图像的云雾去除中，展现出了巨大的潜力。风格迁移不仅能够有效保持原始图像的内容与结构信息，还能够通过学习无云雾图像的风格特征，将受云雾影响的图像转换为清晰、无干扰的图像，从而提升图像的可用性和解译的准确性，最终达到去除光学遥感图像中云雾的效果。然而，将风格迁移应用于光学遥

感图像的云雾去除领域仍然是一个新兴的研究方向。据本文所知,在现有研究中,尚未有将风格迁移技术应用于此类问题的成果。

本文首次提出了一种基于风格迁移的光学遥感图像云雾去除方法。该方法通过深度学习模型的训练,使得原本受云雾影响的遥感图像在较小损失地物信息的前提下,显著提升了图像的清晰度和可用性。风格迁移技术能够有效保持原始图像的内容和结构信息,同时通过学习无云雾图像的风格特征,将受云雾影响的图像转换为清晰、无干扰的图像,从而提高图像解译的准确性和可靠性。我们希望通过这一创新方法,为遥感图像的后续分析与应用提供更加可靠的数据支持,进一步推动光学遥感技术在实际场景中的广泛应用。

为了获取高质量的训练数据,以支持和增强云雾去除算法的性能,本文还改进并开发了一种新型云雾生成算法。云雾去除任务的评估通常依赖于大规模的标注数据集,这些数据集需要包含多种类型的云雾干扰以及相应的无云雾图像。然而,在实际场景中,使用卫星或无人机获取足够多的真实云雾和对应的无云雾配对的光学遥感图像往往较为困难,这限制了深度学习模型的训练效果和泛化能力。

通过开发一个云雾生成算法,可以从清晰的遥感图像中生成带有云雾干扰的图像,创建大规模、可控的训练数据集。该算法能够模拟不同类型的云雾,包括薄云和厚云,甚至云影的生成,从而覆盖各种可能出现的云雾场景。这种方法不仅解决了训练数据不足的问题,还允许研究人员根据不同的实验需求调整云雾的特性,从而更有针对性地训练云雾去除模型。

此外,生成的云雾数据还能帮助模型学会识别和去除特定类型的云雾干扰,从而提升模型的鲁棒性和适应性。总体而言,云雾生成算法的开发为提升云雾去除技术提供了重要的数据支持,并为进一步研究和实际应用奠定了基础。

总体而言,本文基于风格迁移的云雾去除算法具有较优的性能,本文使用 RSSCN7<sup>[3]</sup>数据集作为基础生成对应的云雾数据 RS7Cloud,并在该数据集上进行训练。训练完毕后使用 RICE<sup>[4]</sup>数据集进行测试,本文方法在结构相似性指数(structural similarity index, SSIM)与峰值信噪比(Peak Signal to Noise Ratio, PSNR)方面与其他文章相比均具有一定优势。

总体而言,本文的工作包括以下几点:

1. 本文提出了一种基于风格迁移的光学遥感图像云雾去除方法,这是目前已知的首个将风格迁移应用于此领域的研究。该方法通过深度学习模型的训练,在保持原始图像内容和结构信息的前提下,有效去除了云雾干扰,显著提升了图像的清晰度和可用性。
2. 本文开发并改进了一种云雾生成算法以解决云雾去除任务中训练数据不足的问题。该算法能够在清晰的遥感图像上生成带有云雾干扰的图像,从而创建大规模、可控的训练数据集。这一创新不仅补充了现有数据集的不足,还增强了模型在识别和去除云雾方面的鲁棒性和适应性。
3. 通过生成不同类型的云雾,包括薄云、厚云和云影,本文的方法为云雾去除模型的训练提供了丰富的数据支持,进而提升了模型在实际应用中的性能。这为遥感图像分析与解译提供了更加可靠的数据基础,有助于推动光学遥感技术在各种实际场景中的广泛应用。

## 2 相关工作

### 2.1 云雾去除

由于地球上空常年存在的大量云雾<sup>[1]</sup>,众多遥感在拍摄光学遥感图像时会受其严重影响。最终获得的光学遥感图像中存在大量地物边界模糊、纹理丢失、地表目标完全遮挡等问题,

这将使光学遥感图像的价值大幅降低,并使某些地区本就稀少的光学遥感图像的可用数量进一步下降。因此,光学遥感图像的去云处理能够从一定程度上恢复光学遥感图像原本的信息,为进一步的遥感分析提供可靠数据。当前的光学遥感图像云雾去除算法主要分为三类:1.基于图像变换的方法,2.基于先验数据的方法,3.基于机器学习的方法。

基于图像变换的方法通过传统的数字图像处理技术,通过增强云雾图像中的对比度等方法,提升图像清晰度,并尽量降低云雾对遥感图像数据的影响。Richter 等人<sup>[5]</sup>使用缨帽变化法对光学遥感图像进行处理,基于结果的第四分量来自原图像中云雾这一特点,结合与无云雾图像的直方图匹配实现了光学遥感图像中的云雾去除。Cai 等人<sup>[6]</sup>使用同态滤波实现了云层厚度自适应的云雾去除。他们使用 LISA 分析获取光学遥感图像中的云层覆盖区域,并使用具有不同截止频率的同态滤波器完成自适应云雾去除工作。

基于先验数据的方法需要大量云雾—晴天数据对,通过分析该类数据对的统计特征,挖掘二者在数字图像、遥感地理信息、光学波段之间的差异,从而用统计方法获取先验知识,并在该先验知识的引导下完成云雾去除工作。由 Zhang 等人<sup>[7]</sup>率先提出的霾优化变换(Haze-Optimized Transformation, HOT)是一种具有代表性的基于先验数据的云雾去除算法。该方法统计并分析了遥感图像规律,提出了 HOT,即在多光谱遥感图像中,云雾(尤其是薄云或薄雾)对不同波段的影响具有一致的特性。这种一致性使得在某些波段组合(通常是近红外和短波红外波段)上,云雾的影响可以通过特定的变换或计算得到减弱甚至去除。HOT 假设利用了这种一致性来进行云雾的检测和去除。除此之外,暗目标减法<sup>[8]</sup>、暗通道先验法<sup>[9]</sup>也是常用的基于先验数据的云雾去除方法。

随着机器学习的发展,一些研究者试图将机器学习尤其是深度学习与云雾去除结合。Cai 等人<sup>[10]</sup>以卷积神经网络(Convolutional Neural Network, CNN)为基础,提出了 DehazeNet 网络。基于该网络估计得到的大气投射率,Cai 等人<sup>[10]</sup>结合大气散射模型从云雾图像中恢复晴空图像。Pan 等人<sup>[2]</sup>提出了一种基于生成式对抗网络(Generative Adversarial Networks, GAN<sup>[11]</sup>)的云雾去除方法,其名为 Spatial Attention Generative Adversarial Network (SpA GAN)。该网络首次在云雾去除任务中引入了空间注意力机制,通过模拟人类视觉系统的机制,识别并聚焦云区,增强这些区域的信息恢复能力。

## 2.2 图像风格迁移

图像风格迁移可以被定义为如下任务:在图像域中获取一张风格化图像,该风格化图像具有某张特定图像的内容信息,同时与另一张图像的风格信息类似。风格迁移任务中,提供内容信息的图像被称作内容图像,提供风格信息的图像被称作风格图像。尽管风格迁移工作中风格图像往往是艺术作品,但也可以由真实图像提供所需的风格信息。

风格迁移算法的出现可以追溯到 20 世纪 90 年代中期<sup>[12]</sup>。从该时期开始到 2016<sup>[13]</sup>出现的风格迁移成果往往以数学建模或纹理模拟为主要特征,该类成果被归为传统风格迁移成果。传统风格迁移成果可以通过多种方式实现,基于风格原语的风格迁移(Primitives-Based Rendering, PBR)是一个较为常见的方法。该类方法的核心思想是于空白图像上操作如虚拟笔触、点划与阴影等风格原语,以模拟特定风格。这些风格原语在 EBR 算法的处理下自动编辑一个或多个空白图像,以类似绘画的方式完成风格化。该类方法的优势在于能够模拟多样化的艺术风格,且在处理细节方面具有较高的精度。

基于图像示例的风格迁移方法是另一种传统风格迁移方法,该方法通过分析一个内容—风格示例对学习二者之间的映射关系。内容—风格示例对是一组图像信息的两个不同版本,二者具有相同或类似的内容信息与差别较大的风格信息。获取映射关系后,该这类方法通常编码一组启发式规则,以描绘预定的风格。这种方法的优势在于可以产生高度个性化的结果,但该方法依赖于高质量的内容—风格示例对,在训练数据方面获取困难。

基于滤镜的风格迁移则是利用各种图像处理滤镜以实现风格迁移的传统风格迁移方法。该类利用交互技术（如人类注视追踪器、重要性图等）以探索风格图像的不同层次，通过分割源图像的不同分辨率版本构建的区域包含层级，以实现不同层次的抽象表示，最终创建不同滤镜。其优势在于可以快速并简单的实现风格迁移工作，但无法胜任模拟精确的风格细节。

随着深度学习的发展，风格迁移也由传统方法向深度学习方法转变，利用神经网络进行风格迁移的方法被称作神经风格迁移。神经风格迁移从 2016 年<sup>[13]</sup>发展至今可以大致分为两个阶段：基于像素迭代的风格迁移、基于模型迭代的快速风格迁移。

基于像素迭代的风格迁移方法是神经风格迁移发展的第一阶段。作为早期阶段，该类方法的核心思想在于利用神经网络与损失函数优化噪声图，该噪声图中的数值被认为是神经网络中的参数，并利用损失函数对该噪声图进行反向传播，以达成风格迁移的目标。Gatys 等人<sup>[13]</sup>于 2016 年率先将 CNN 与风格迁移结合，利用一个预训练的图像分类网络 VGG19<sup>[14]</sup>计算 Gram 矩阵以提取图像特征并计算损失函数，开创了神经风格迁移的先河。Risser 等人<sup>[15]</sup>在 Gatys 等人<sup>[13]</sup>的成果上进行优化，将原图与特征图的直方图纳入损失函数考量，使风格迁移质量更加稳定。Li 等人<sup>[16]</sup>试图解释 Gatys 等人<sup>[16]</sup>方法的原理，并发现该方法可以视作领域自适应方法的一个变种。同时，他们还研究 Gatys 等人<sup>[16]</sup>方法中的 Gram 矩阵，并证明了该矩阵在本质上与最小化一个具有二次多项式核的最大均值差异（Maximunn Disvrepaney，MMD）相同，该差异是一个领域自适应任务中常用的损失函数。以此为基础，Li 等人<sup>[16]</sup>认为，使用其他领域自适应任务中常见的损失，也能达成风格迁移的效果。以上第一阶段的风格迁移成果均有一个明显的缺陷，即运算时间过长，使用 Gatys 等人<sup>[16]</sup>方法完成单张  $512 \times 512$  图像的风格迁移任务需要超过 50 秒<sup>[16]</sup>，其时间成本难以令人接受。其他方法在未优化特征提取网络结构的前提下增加了多种损失函数，使运算量进一步提升，运算时间与 Gatys 等人方法相比更长。在面临大量图像需要风格迁移时，该缺点尤为明晰。

注意到运算时间导致的应用范围狭窄问题，为了提升神经风格迁移的效率，研究人员试图以迁移质量或单模型能迁移风格的种类为代价实现快速风格迁移，这一阶段的成果被称作基于模型迭代的快速风格迁移，即神经风格迁移第二阶段。实现该思路的主要方式如下：改风格迁移第一阶段中优化噪声图像的思想为优化神经网络的思想，将推理所需时间前置为训练所需时间。在具体实现层面，主要实现方法为训练一个特定的风格迁移网络，将风格信息以参数的形式保留在网络中。在面对不同风格时，调整网络模型参数，从而完成快速风格迁移。Johson 等人<sup>[16]</sup>与 Ulyanov<sup>[17]</sup>等人率先且彼此独立的发表了实时风格迁移工作，双方的想法类似，但具体实现细节略有不同。核心思想为训练一个前馈神经网络，以神经网络中的参数保存风格化信息，如此便无须在风格迁移时优化噪声图像，而是直接修改内容图像。尽管二人的方法极大降低了基于图像迭代的风格迁移的运算时间，但这是以迁移风格种类为代价的，每个训练完成的前馈神经网络只能迁移某种特定的风格，这使得这类方法在灵活性方面有所欠缺。Dumoulin 等人<sup>[18]</sup>率先将特定风格与神经网络中的特定层绑定，从而实现了单模型生成多风格的风格迁移。为了减少多种风格保留在神经网络中的大量参数，他们发现不同风格中的特定部分可以用相同参数的线性变换与组合表示，并提出了自条件归一化（Conditional Instance Normalization，CIN）操作。尽管 Dumoulin 等人<sup>[18]</sup>的成果可以以较低的时间代价迁移多种风格，但随着迁移种类的提升，网络参数量越发庞大，从而限制了其应用。Huang 等人<sup>[19]</sup>受到 Dumoulin 等人<sup>[18]</sup>等人的启发，提出了自适应实例归一化（Adaptive Instance Normalization，AdaIN）方法。该方法通过实现内容特征与风格特征的均值与方差的相互对应与匹配实现了任意且实时的风格迁移。该方法能够以极低的时间代价完成且能迁移任意风格，但由于 AdaIN 的简单设计导致其风格化精细度不高。除此之外，Zhu 等人<sup>[20]</sup>基于 GAN 提出的 CycleGAN、Liu 等人<sup>[21]</sup>利用注意力机制提出的自适应注意力归一化（daptive

批注 [XZ1]: 若最终相关技术过于冗余，可以删除这一部分

Attention Normalization, AdaAttN)、Kwon 等人<sup>[22]</sup>基于 CLIP 大模型提出的 ClipStyler 均可以完成风格迁移任务。

风格迁移作为一个将源域中图像迁移到另一个域中的方法,通过学习目标图像的风格特征,能够实现图像在不同风格之间的转换,这与云雾去除任务的目标相同。

### 3 方法

#### 3.1 云雾生成算法

云雾去除任务的评估通常依赖于大规模的标注数据集,这些数据集需要包含多种类型的云雾干扰以及相应的无云雾图像。然而,在实际场景中,使用卫星或无人机获取足够多的真实云雾和对应的无云雾配对的光学遥感图像往往较为困难,这限制了深度学习模型的训练效果和泛化能力。本文完善并改进了 Sun 等人<sup>[23]</sup>的云雾生成算法。Sun 等人<sup>[23]</sup>的算法只能随机生成云雾,无法模拟不同的云雾类型,且随机性有所不足。本文改进后的算法能够模拟不同类型的云雾,包括薄云和厚云,甚至云影的生成,从而覆盖各种可能出现的云雾场景,其计算过程如下:

##### 1. 初始噪声生成

首先生成一个初始噪声图像 $B(x, y)$ ,其尺寸为原始图像尺寸的一半,为 $(\frac{H}{2}, \frac{W}{2})$ ,像素值在 $[0, 255]$ 之间均匀分布。这一步骤创建了一个基础的随机噪声图像,为后续的云层生成提供了基础。

$$B(x, y) \sim \text{Uniform}(0, 255), x \in [0, \frac{H}{2}], y \in [0, \frac{W}{2}] \quad 1$$

##### 2. 云图生成

其次,利用多尺度的噪声生成方法来创建更为逼真的云图。我们定义了一个多尺度噪声尺寸范围 $p$ ,并在此范围内选择不同的尺度。

$$p = \{k^s \mid s = 2, 3, \dots, \log_2(\min(H, W))\} \quad 2$$

对于每个尺度 $p$ ,从原始噪声 $B(x, y)$ 中随机选取一个 $p \times p$ 的子矩阵 $Q_p$ :

$$Q_p(x, y) = B(x + x_0, y + y_0), x_0 \in [0, \frac{H}{2} - p], y_0 \in [0, \frac{W}{2} - p] \quad 3$$

将 $Q_p$ 进行上采样至原始图像尺寸 $H \times W$ ,得到上采样后的噪声图 $U_p(x, y)$ :

$$U_p(x, y) = \text{Resize}(Q_p, (H, W)) \quad 4$$

不同尺度的噪声图经过累积和归一化处理,最终生成完整的云图 $T(x, y)$

$$\begin{aligned} T(x, y) &= \sum_{p \in P} \frac{U_p(x, y)}{p} \\ T(x, y) &= \frac{T(x, y)}{\sum_{p \in P} \frac{1}{p}} \end{aligned} \quad 5$$

##### 3. 云层叠加

在云层叠加阶段,需要将生成的云图 $T(x, y)$ 与原始图像 $I(x, y)$ 结合,生成带有云层的图像 $I_c(x, y)$ 。

首先,通过计算前景图 $F(x, y)$ ,将云图与原始图像结合。前景图 $F(x, y)$ 的计算方式确保了云层的厚度可以通过参数 $k$ 进行调节,从而控制云层对原始图像的遮挡程度。

$$F(x,y)=\frac{255-T(x,y)}{255k}$$

6

最后，带有云层的图像 $I_c(x,y)$ 通过将云图与前景图叠加生成，形成最终的模拟云雾图像：

$$I_c(x,y)=I(x,y)\cdot F(x,y)+T(x,y)$$

7

3.2 云雾去除算法

云雾 qiu

4 实验

4.1 数据集

4.2 评价指标

4.3 实验环境设置

4.4 云雾生成质量

4.5 云雾去除质量

5 总结

引用